

Universidad Europea

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

INGENIERÍA INFORMÁTICA

PROYECTO COMPUTACIÓN I

Preparación y análisis exploratorio de datos de Aruba

ETL y EDA · Memoria de entrega intermedia

GRUPO 2

José Fernández Tébar

Gino Milthon Levano Carhuancho

Javier Belloch Molinero

Iván Sanz López

Miguel Ángel Carpio Cornejo

Profesora: Isabel Sutil Martín

Curso 2026–2027

6 de noviembre de 2026

Ficha del proyecto

TÍTULO: Preparación y análisis exploratorio de datos de Aruba

AUTORES: José Fernández Tébar, Gino Milthon Levano Carhuancho, Javier Belloch Molinero, Iván Sanz López, Miguel Ángel Carpio Cornejo

TITULACIÓN: Ingeniería Informática

ASIGNATURA: Proyecto Computación I

PROFESORA: Isabel Sutil Martín

FECHA: 6 de noviembre de 2026

VERSIÓN: 1 · Fuentes externas y primera integración

Esta memoria recoge la aportación disponible para la fase de extracción, transformación y carga de datos (ETL) y su análisis exploratorio (EDA).

Índice de contenidos

1 Desarrollo del proyecto 5
1.1 Descripción de la solución y herramientas empleadas 5
1.1.1 Objetivo y alcance de esta fase 5
1.1.2 Conjuntos de datos y función de cada fuente 5
1.1.3 Exploración inicial de la meteorología 6
1.1.4 Limpieza y control de calidad de las fuentes 7
1.1.5 Integración de las fuentes y comprobaciones 8
1.1.6 Ingeniería de características 9
1.2 Resultados del proyecto 11
1.2.1 Análisis univariante de la meteorología 11
1.2.2 Relaciones entre variables y datos anuales 12
1.2.3 Estado actual y siguientes aportaciones 13
1.2.4 Preparación de la siguiente fase 13
2 Bibliografía 14
3 Anexos 15
3.1 Archivos utilizados y trazabilidad 15
3.2 Registro de ampliaciones pendientes 16

Índices de tablas y figuras

Tablas

Tabla 1. Fuentes disponibles y función de cada conjunto 5
Tabla 2. Variables meteorológicas y unidades de trabajo 7
Tabla 3. Comprobaciones de calidad de las fuentes 8
Tabla 4. Comprobaciones de la primera integración 9
Tabla 5. Variables derivadas presentes en los archivos 10
Tabla 6. Variables propuestas para la siguiente versión 10
Tabla 7. Estadísticos descriptivos de la meteorología 11
Tabla 8. Correlaciones meteorológicas 12
Tabla 9. Archivos utilizados y trazabilidad 15

Figuras

Figura 1. Distribuciones de las variables meteorológicas 11
Figura 2. Relación entre velocidades del viento y producción anual 12

1 Desarrollo del proyecto

1.1 Descripción de la solución y herramientas empleadas

El trabajo utiliza Python y pandas para cargar, transformar y relacionar tablas; notebooks para registrar la limpieza; y archivos JSON, CSV y Excel como entradas o salidas. Los gráficos y estadísticos incluidos documentan la exploración disponible. El proyecto y su planificación se describen en los documentos de referencia [1] y [2].

1.1.1 Objetivo y alcance de esta fase

El objetivo de esta actividad es reunir y comprender los datos del proyecto energético de Aruba, revisar su calidad e incorporar información útil para preparar el posterior modelado. El proyecto plantea anticipar la potencia o el consumo eléctrico a 15 minutos y utilizar el histórico reciente mediante variables de retardo.

Esta fase recoge la preparación de cinco fuentes externas, su análisis exploratorio y una primera integración con las lecturas de las estaciones.

1.1.2 Conjuntos de datos y función de cada fuente

Fuente	Dimensiones	Contenido y utilidad
Meteorología	62.109 × 20	Condiciones horarias en nueve puntos geográficos. Fuente externa para enriquecer las lecturas.
Producción histórica	16 × 3	Producción anual de 2010 a 2025. Contexto y análisis de tendencias.
Interrupciones	6 × 5	Duraciones anuales de 2020 a 2025. Contexto sobre interrupciones del suministro.
Equipos instalados	8 × 6 y 2 × 2	Inventario de generación y almacenamiento, más dos métricas de demanda estimada de 2026.
Turbinas	28 × 5	Especificaciones de un modelo Vestas V90-3.0. Son características, no 28 turbinas.
Primera integración	421.497 × 60	Lecturas con información de estaciones y meteorología; cruce anual sin coincidencias.

Tabla 1. Fuentes disponibles y función de cada conjunto

Los libros Excel permiten consultar las tablas y calcular los estadísticos y gráficos presentados en esta memoria. Como comprobación complementaria se analiza el CSV de la primera integración. Se

conserva la distinción entre las transformaciones recogidas en los scripts y los cálculos exploratorios realizados para documentar los datos.

Las referencias de archivos, los scripts examinados y los límites de trazabilidad se recogen en la bibliografía y en el anexo 3.1.

Versión 1: documentación de las fuentes recibidas y de la primera integración. Los resultados analíticos de esta memoria corresponden a los archivos enumerados en el anexo 3.1.

1.1.3 Exploración inicial de la meteorología

Cada fila corresponde a una hora y un punto de coordenadas. El periodo abarca del 1 de enero de 2026 a las 00:00 al 15 de octubre de 2026 a las 12:00. Hay 6.901 instantes horarios y nueve puntos por instante, que explican las 62.109 observaciones. La secuencia de horas no presenta huecos y la clave time, latitude, longitude no se repite.

Variables	Tipo observado	Interpretación y unidad
time	Fecha y hora	Marca temporal horaria. En Excel no conserva zona horaria; debe verificarse antes del cruce.
latitude, longitude	Numérico	Coordenadas. Latitud de 12,25 a 12,75 y longitud de −70,25 a −69,75.
sp, sp_hPa	Numérico	Presión original y conversión a hPa. La relación entre ambas es una división entre 100.
t2m, t2m_C	Numérico	Temperatura original y conversión a °C mediante resta de 273,15.
u10, v10, u100, v100	Numérico	Componentes del viento a 10 y 100 m; unidades de trabajo interpretadas como m/s.
vel_viento_10m, vel_viento_100m	Numérico	Módulos de la velocidad del viento calculados a partir de sus componentes.
dir_viento_100m	Numérico	Dirección del viento a 100 m expresada en grados; convención por confirmar.
tcc	Numérico	Nubosidad en fracción entre 0 y 1.
blh, fsr, i10fg	Numérico	Nombres compatibles con altura de capa límite, rugosidad y racha a 10 m. Confirmar definiciones y unidades con la fuente.

Variables	Tipo observado	Interpretación y unidad
ssrd, ssrd_Wm2	Numérico	Radiación original y columna derivada mediante división entre 3.600. La interpretación física requiere revisar la acumulación temporal.

Tabla 2. Variables meteorológicas y unidades de trabajo

Información adicional relevante

La meteorología a mayor altura puede ayudar a caracterizar el recurso eólico. El inventario aporta capacidades nominales y las fichas técnicas permiten estudiar límites de operación. Para entrenar y validar una predicción energética hace falta, además, una serie temporal del objetivo y una definición clara de su ámbito: estación, parque o isla.

1.1.4 Limpieza y control de calidad de las fuentes

Transformaciones realizadas

El notebook de datos externos elimina duplicados meteorológicos por tiempo y coordenadas, convierte la fecha, ordena la tabla y sustituye nulos de radiación por cero. En las otras fuentes aplana estructuras anidadas, convierte tipos numéricos, elimina duplicados anuales y transforma duraciones de horas y minutos a horas decimales. Las conversiones de viento, temperatura y presión ya llegan en el CSV que lee el notebook; su cálculo inicial no aparece en ese notebook.

Comprobación	Resultado en los Excel
Nulos y duplicados completos	Meteorología, producción, interrupciones y turbinas: sin nulos ni filas completas duplicadas.
Datos de equipos	4 nulos en motores_motores; 1 en capacidad_mw; 7 en potencia_mw y 7 en capacidad_mwh. Muchos representan campos no aplicables al equipo.
Tipos en turbinas	La columna valor mezcla texto, números y unidades, por ejemplo 3,000.0 kW. Requiere extracción numérica si se usa para cálculos.
Coherencia básica	Nubosidad entre 0 y 1; velocidades no negativas; direcciones entre 43,22 y 137,03 grados. No se detectan infracciones de esos límites.
Radiación negativa	15.396 registros negativos, el 24,79 % de las filas meteorológicas.
Categorías	El inventario presenta tres grupos de equipos. En la ficha de turbinas aparecen etiquetas poco claras como planear y alturas; necesitan un diccionario.

Tabla 3. Comprobaciones de calidad de las fuentes

Radiación y valores ausentes

La salida guardada del notebook registra 5.184 valores ausentes tanto en ssrd como en ssrd_Wm2 antes del relleno. Que falte una medición no demuestra que sea de noche. Se debe justificar la imputación mediante la documentación y el comportamiento horario. Los negativos y la media de la variable derivada hacen necesario revisar el tratamiento de la radiación antes de usarla en un modelo; no se han corregido automáticamente en este informe.

Comprobación de conversiones

Los valores de viento coinciden con el módulo de sus componentes con errores máximos menores de 0,000002 m/s. Las conversiones a °C y hPa presentan diferencias inferiores a 0,0001, compatibles con el redondeo. La igualdad numérica entre ssrd_Wm2 y ssrd dividido entre 3.600 no demuestra que la acumulación original corresponda a una hora; ese supuesto se debe confirmar.

La carga y limpieza se recogen en los notebooks [3] y [4]. La primera unión se ha revisado en el script [5]. Los nombres exactos de entradas y salidas figuran en el anexo 3.1.

1.1.5 Integración de las fuentes y comprobaciones

El script unico dataset.py parte de objetos ya existentes en memoria. Ordena por fecha, descarta fechas nulas y aplica merge_asof hacia atrás entre timestamp y time. Después realiza uniones por year con interrupciones y producción. El resultado contiene datos de estaciones, aunque la celda que los incorpora no aparece en el script compartido.

Indicador del dataset integrado	Resultado comprobado
Dimensiones y periodo	421.497 filas y 60 columnas; del 31 de marzo al 30 de junio de 2026.
Fechas y duplicados completos	Sin fechas inválidas ni filas completamente idénticas en el CSV.
Clave station_id y timestamp	107.084 filas adicionales respecto a claves únicas, el 25,41 %. No se puede atribuir su origen al merge sin los conteos previos.
Correspondencia de estaciones	12 nombres de estación identificados; 4 filas sin nombre ni coordenadas de estación. Hay 2 station_id nulos y 14 valores distintos no nulos.
Correspondencia meteorológica	Todas las filas tienen time. Diferencia temporal observada entre 0 y 55 minutos.
Cruces anuales	Las cuatro columnas de interrupciones y las dos de producción quedan nulas en el 100 % de las filas.

Indicador del dataset integrado	Resultado comprobado
Columnas de esquema corrupto	17 columnas anómalas entre uv_index y year, como prressure_hpa y tempertimestamp, vacías o con un único dato.
Conservación de filas	No se puede verificar el cambio total de observaciones sin la tabla inmediatamente anterior a cada cruce.

Tabla 4. Comprobaciones de la primera integración

Correspondencia geográfica en la primera integración

La tabla meteorológica tiene nueve puntos por hora. Al cruzar únicamente por tiempo, merge_asof selecciona una fila entre las disponibles para esa hora. En el resultado todas las estaciones reciben el mismo dato meteorológico para un mismo time. Falta asignar cada estación a un punto de la rejilla o definir una agregación espacial justificada.

Además, el script elimina las columnas con sufijo _y sin comprobar su significado. Esto puede descartar las coordenadas del punto meteorológico y dificultar la trazabilidad. Se deben conservar nombres explícitos para las coordenadas de la estación y las del punto externo.

Ajustes previstos para la integración

Validar estaciones y lecturas; resolver claves repetidas según el contenido; asignar un punto meteorológico por proximidad u otro criterio documentado; normalizar zonas horarias; aplicar el cruce temporal por el punto asignado y con tolerancia explícita. Después, registrar filas antes y después, coincidencias, distancia temporal, nulos nuevos y unicidad de las claves. Los datos anuales pueden mantenerse como tablas de contexto separadas.

1.1.6 Ingeniería de características

Cada variable derivada debe responder a una necesidad del problema y poder calcularse con información disponible en el instante de predicción. Conviene separar las transformaciones ya presentes de las propuestas pendientes.

Variables presentes en los archivos

Variable	Transformación observada	Justificación
vel_viento_10m y vel_viento_100m	Módulo de las componentes u y v.	Resumir la intensidad del viento para estudiar el recurso eólico.

Variable	Transformación observada	Justificación
t2m_C y sp_hPa	Conversión de temperatura y presión.	Interpretar las magnitudes y comparar con las lecturas locales.
ssrd_Wm2	División de ssrd entre 3.600.	Pretende expresar flujo medio. Pendiente de validar la acumulación original.
total_outage_hours y remaining_allowance_hours	Horas más minutos divididos entre 60, con dos decimales.	Permitir análisis numérico de las duraciones anuales.
year	Año extraído de timestamp.	Clave de unión anual; en la integración es constante e igual a 2026.

Tabla 5. Variables derivadas presentes en los archivos

Variables propuestas para la siguiente versión

Variable propuesta	Sentido para el problema
Hora y mes	Representar ciclos diarios y cambios estacionales. Confirmar zona horaria y codificar ciclos cuando proceda.
Retardos a 5, 10, 15 y 20 minutos	Capturar el estado reciente de la variable energética y del viento, sin mezclar estaciones.
Media y variación de los últimos 20 minutos	Describir tendencia e inestabilidad reciente. La ventana solo puede contener pasado y presente.
Dirección con seno y coseno	Representar la continuidad entre 359 y 0 grados; confirmar primero la convención de dirección.
Potencia o consumo a 15 minutos	Objetivo supervisado: el valor del mismo sistema 15 minutos después del instante de entrada.

Tabla 6. Variables propuestas para la siguiente versión

Los retardos deben construirse tras ordenar y validar la frecuencia. Desplazar tres filas equivale a 15 minutos únicamente si la serie es regular cada cinco minutos y no presenta huecos ni repeticiones. Es preferible comprobar el intervalo exacto mediante las marcas temporales. Las variables energéticas propuestas todavía no existen en la tabla revisada.

1.2 Resultados del proyecto

1.2.1 Análisis univariante de la meteorología

Los siguientes estadísticos se han calculado sobre las 62.109 filas del Excel, agrupando los nueve puntos y todas las horas. Describen este conjunto y no representan 62.109 observaciones temporalmente independientes. La desviación típica es muestral.

Variable	Media	Mediana	Desv	Mínimo	Máximo
Viento 10 m · m/s	9,48	9,67	1,51	2,53	13,52
Viento 100 m · m/s	11,40	11,62	2,04	2,80	17,33
Temperatura · °C	27,06	26,99	0,86	24,26	29,40
Presión · hPa	1.011,96	1.011,99	1,66	1.005,93	1.018,05
Nubosidad · fracción	0,50	0,43	0,37	0,00	1,00
Radiación · W/m²	3,63	0,00	112,50	-363,73	396,85

Tabla 7. Estadísticos descriptivos de la meteorología

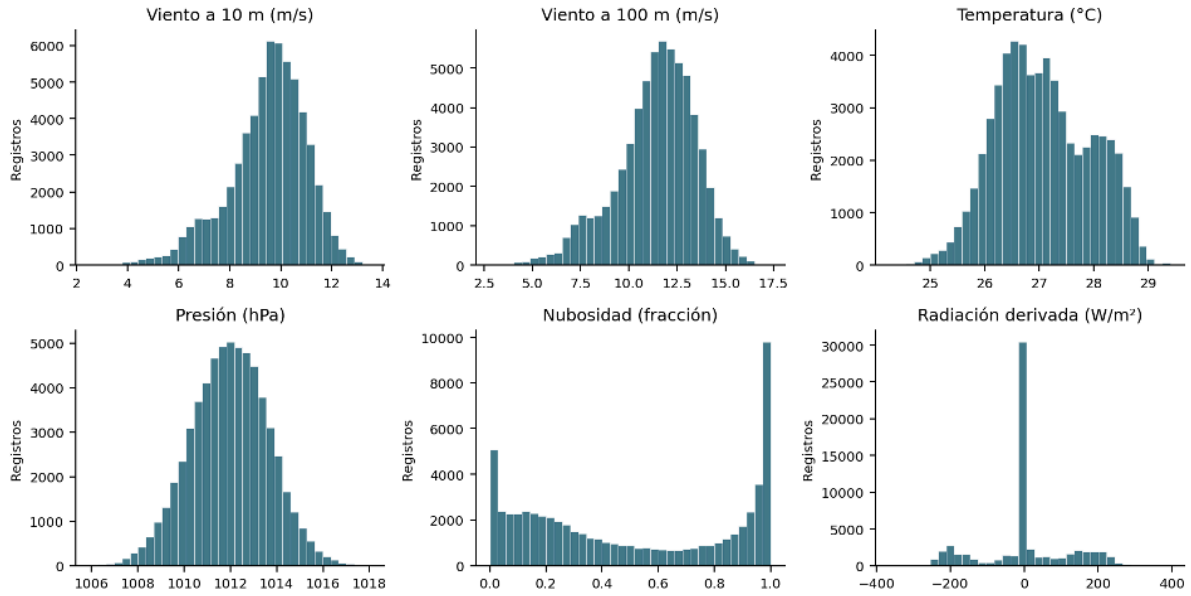


Figura 1. Distribuciones de las variables meteorológicas. Fuente: elaboración a partir de los Excel analizados.

El viento a 100 m presenta una media de 11,40 m/s, superior a los 9,48 m/s de 10 m. La temperatura se concentra alrededor de 27 °C y la presión alrededor de 1.012 hPa. La radiación tiene una mediana

de cero y valores negativos; su media no debe interpretarse todavía como una estimación válida del recurso solar.

Detección exploratoria de valores atípicos

La regla de 1,5 veces el rango intercuartílico señala 1.287 filas en viento a 10 m, 1.090 en viento a 100 m, 10 en temperatura y 339 en presión. Son candidatos a revisión, no errores demostrados. En radiación señala 25.736 filas; su distribución y los problemas previos hacen inadecuado eliminar esos registros solo por esta regla. La nubosidad no presenta candidatos según el mismo criterio.

1.2.2 Relaciones entre variables y datos anuales

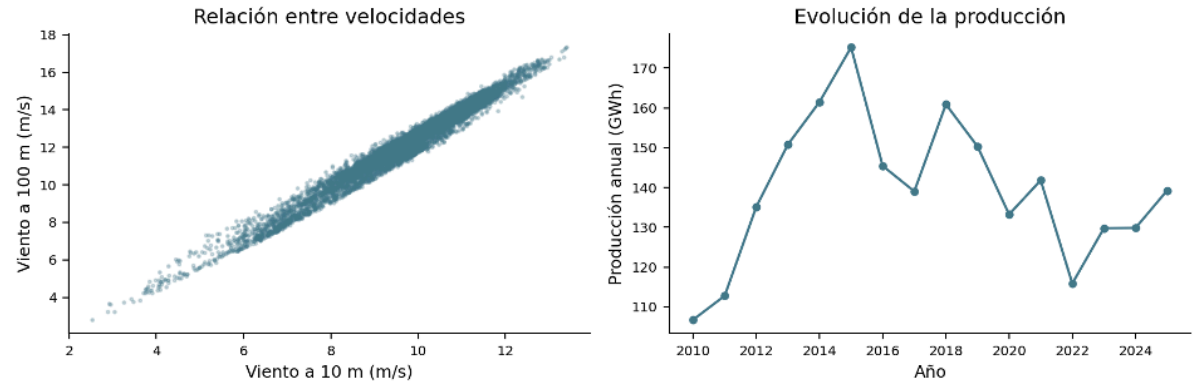


Figura 2. Relación entre velocidades del viento y producción anual. Fuente: elaboración a partir de los Excel analizados.

A la izquierda se representa uno de los nueve puntos de la rejilla, con 6.901 horas. A la derecha figura la producción anual completa de 2010 a 2025.

Relaciones meteorológicas

Par de variables	Correlación de Pearson	Lectura exploratoria
Viento 10 m y viento 100 m	0,977	Relación positiva fuerte. Pueden aportar información parcialmente redundante.
Temperatura y viento 100 m	0,215	Asociación lineal débil en el conjunto analizado.
Temperatura y presión	-0,206	Asociación lineal negativa débil.

Tabla 8. Correlaciones meteorológicas

Las correlaciones se calculan con los nueve puntos y todas las horas. Se interpretan como relaciones descriptivas, teniendo en cuenta la dependencia espacial y temporal de las observaciones. El análisis

respecto al objetivo energético se incorporará junto con la aportación del equipo que lo defina. Las relaciones con radiación se revisarán tras validar su transformación.

Producción e interrupciones

La producción anual media es de 139.231,38 MWh y la mediana de 139.140 MWh. El mínimo corresponde a 2010, con 106.742 MWh, y el máximo a 2015, con 175.244 MWh. El porcentaje capacity_percent varía del 40,6 al 66,7; su denominación y fórmula deben confirmarse antes de presentarlo como un indicador concreto de rendimiento.

Los archivos anuales sí comparten los años 2020 a 2025. Un cruce exploratorio por year produce seis pares sin duplicados de año y una correlación de −0,332 entre producción e interrupciones en horas. Con solo seis observaciones, este resultado es descriptivo y no permite atribuir cambios de producción a las interrupciones. Este cruce se utiliza para el análisis anual y no completa el objetivo a 15 minutos.

La capacidad instalada se expresa en MW, mientras que la producción anual está en MWh. Son magnitudes distintas: potencia y energía. La batería también distingue potencia en MW de energía almacenada en MWh; no deben sumarse entre sí como si compartieran unidad.

1.2.3 Estado actual y siguientes aportaciones

Esta versión documenta los conjuntos de datos disponibles, las transformaciones de limpieza, los primeros resultados del EDA y las comprobaciones de integración.

Esta aportación se ampliará con la validación de lecturas, el tratamiento de anomalías, la curva de potencia, la potencia eólica estimada y el remuestreo a cinco minutos previstos para el sprint 1 [2]. Estas tareas siguen pendientes de incorporación.

Para cerrar el hito ETL se comprobará la ejecución completa mediante un único comando, la disponibilidad del dataset integrado y depurado y el README con dependencias, entradas, salidas e instrucciones. Estas comprobaciones corresponden al paquete conjunto del equipo.

1.2.4 Preparación de la siguiente fase

En el sprint 2 se definirán los retardos, los objetivos futuros y la división cronológica train/test [2]. El tramo más reciente se reservará para prueba, sin emplear información futura. Los periodos definitivos se fijarán tras consolidar la frecuencia y la variable energética.

La potencia obtenida de la curva de turbina se identificará como estimada y se distinguirá de la producción medida.

2 Bibliografía

[1] Equipo docente. Proyecto Aruba. Enunciado del proyecto. Documento docente facilitado al equipo, s. f.

[2] Equipo del proyecto. Product Backlog Gemelo Digital Aruba. Planificación del sprint 1 y siguientes. Documento de trabajo, s. f.

[3] Equipo del proyecto. limpieza_de_datos_raw.ipynb. Notebook de carga y limpieza de lecturas y estaciones. Archivo de trabajo recibido, 2026.

[4] Equipo del proyecto. limpieza_de_codigo_external.ipynb. Notebook de limpieza de las fuentes externas. Archivo de trabajo recibido, 2026.

[5] Equipo del proyecto. unico dataset.py. Script de primera integración. Archivo de trabajo recibido, 2026.

[6] Equipo del proyecto. Libros Excel de meteorología, producción histórica, interrupciones, equipos y turbinas. Archivos de datos descritos en la tabla 9, 2026.

[7] Universidad Europea de Madrid. Plantilla memoria PCI entregas intermedias. Versión 1.0, febrero de 2025.

La procedencia primaria de las fuentes externas se completará con los enlaces originales, las consultas de extracción, las licencias y las fechas de acceso. Los archivos recibidos se identifican como material de trabajo y no sustituyen esas referencias primarias.

3 Anexos

3.1 Archivos utilizados y trazabilidad

El análisis de las fuentes externas se realizó con las hojas completas de los siguientes libros. Las tablas estadísticas y figuras de este informe son cálculos sobre sus valores; los archivos originales no se modificaron.

Archivo	Hoja y uso
datos_meteo_limpio(1).xlsx	Sheet1. Exploración, estadísticos, calidad, conversiones y relaciones meteorológicas.
historical_figures_limpio(1).xlsx	Sheet1. Descripción anual, evolución y cruce exploratorio con interrupciones.
outage_performance_limpio(1).xlsx	Sheet1. Duraciones decimales y análisis anual.
equipment_installed_limpio(1).xlsx	Capacidad_Instalada y Demanda_2026. Inventario, unidades y valores no aplicables.
turbinas_limpio(1).xlsx	Sheet1. Estructura y características del modelo de turbina.
dataset_final_ia.csv	Auditoría complementaria de la integración. No se asume equivalencia celda a celda con su copia Excel.
Notebooks y script	limpieza_de_datos_raw.ipynb, limpieza_de_codigo_external.ipynb y unico dataset.py. Revisión de las transformaciones.
Proyecto_Aruba.pdf	Objetivos, preparación temporal, predicción a 15 minutos y requisitos de evaluación.

Tabla 9. Archivos utilizados y trazabilidad

Extracción y reproducibilidad

Los notebooks de limpieza parten de archivos locales ya obtenidos. No contienen la descarga meteorológica ni la extracción web de las fuentes anuales y técnicas. La ficha de turbinas conserva un enlace a wind-turbine-models.com para Vestas V90-3.0; el informe no verifica esa página ni atribuye a ella mediciones temporales. Queda pendiente registrar las referencias originales, fechas de acceso, permisos de uso y consultas de extracción de cada fuente.

El notebook de lecturas informa de 825.934 objetos JSON interpretados y 212 fragmentos descartados. Son cifras de su salida guardada, no un recuento reproducido desde el archivo original

en esta revisión. Su búsqueda por expresiones regulares y el descarte de fragmentos pueden perder información; se necesita conservar un registro de rechazos y comprobar el esquema de cada lectura.

La diferencia entre esos objetos interpretados y las 421.497 filas integradas no permite deducir por sí sola cuántos registros se eliminaron correctamente. El script de unión depende de variables previamente creadas y no incluye el flujo completo. Para una ejecución reproducible debe incorporar cargas, dependencias, reglas, validaciones y exportación en una secuencia ejecutable desde cero.

3.2 Registro de ampliaciones pendientes

Las siguientes versiones incorporarán las salidas y validaciones aportadas por cada responsable. Para cada etapa se registrarán los archivos de entrada, las reglas aplicadas, los archivos generados y los conteos antes y después. Se actualizarán las tablas, las figuras y los índices al integrar nuevas aportaciones.